Multiclass Text Classification with

Feed-forward Neural Networks and Word Embeddings

Luis Maximiliano López Ramírez - A00833321

First, we will do some initialization.

En este bloque se realiza la configuración inicial del entorno para asegurar que el entrenamiento sea reproducible y eficiente. Se importan las librerías necesarias (random, torch, numpy, pandas, tqdm) y se habilita tqdm para mostrar barras de progreso en pandas. Luego, se configura si se utilizará la GPU (si está disponible) para acelerar el entrenamiento. Finalmente, se establece una semilla aleatoria para asegurar la reproducibilidad de los resultados. Este bloque es similar al anterior código.

In [1]:
```
import random
import torch
import numpy as np
import pandas as pd
from tqdm.notebook import tqdm

# enable tqdm in pandas
tqdm.pandas()

# set to True to use the gpu (if there is one available)
use_gpu = True

# select device
device = torch.device('cuda' if use_gpu and torch.cuda.is_available() else 'cpu')
print(f'device: {device.type}')

# random seed
seed = 1234

# set random seed
if seed is not None:
    print(f'random seed: {seed}')
    random.seed(seed)
    np.random.seed(seed)
    torch.manual_seed(seed)
```

```
device: cuda
random seed: 1234
```

We will be using the AG's News Topic Classification Dataset. It is stored in two CSV files: `train.csv` and `test.csv`, as well as a `classes.txt` that stores the labels of the classes to predict.

First, we will load the training dataset using pandas and take a quick look at how the data.

Se carga el conjunto de datos de entrenamiento desde un archivo CSV, asignando manualmente nombres a las columnas ('class index', 'title', 'description'). Esto organiza los datos para que sean fáciles de manipular y analizar en los siguientes pasos. Este proceso es necesario para estructurar el dataset antes de aplicar cualquier preprocesamiento o entrenamiento del modelo. No hay diferencias significativas con el código anterior en esta parte.

In [2]:
```
train_df = pd.read_csv('train (1).csv', header=None)
train_df.columns = ['class index', 'title', 'description']
train_df
```

Out[2]:

	class index	title	description
0	3	Wall St. Bears Claw Back Into the Black (Reuters)	Reuters - Short-sellers, Wall Street's dwindli...
1	3	Carlyle Looks Toward Commercial Aerospace (Reu...	Reuters - Private investment firm Carlyle Grou...
2	3	Oil and Economy Cloud Stocks' Outlook (Reuters)	Reuters - Soaring crude prices plus worries\ab...
3	3	Iraq Halts Oil Exports from Main Southern Pipe...	Reuters - Authorities have halted oil export\f...
4	3	Oil prices soar to all-time record, posing new...	AFP - Tearaway world oil prices, toppling reco...
...	...	...	...
119995	1	Pakistan's Musharraf Says Won't Quit as Army C...	KARACHI (Reuters) - Pakistani President Perve...
119996	2	Renteria signing a top-shelf deal	Red Sox general manager Theo Epstein acknowled...
119997	2	Saban not going to Dolphins yet	The Miami Dolphins will put their courtship of...
119998	2	Today's NFL games	PITTSBURGH at NY GIANTS Time: 1:30 p.m. Line: ...
119999	2	Nets get Carter from Raptors	INDIANAPOLIS -- All-Star Vince Carter was trad...

120000 rows × 3 columns

The dataset consists of 120,000 examples, each consisting of a class index, a title, and a description. The class labels are distributed in a separated file. We will add the labels to the dataset so that we can interpret the data more easily. Note that the label indexes are one-based, so we need to subtract one to retrieve them from the list.

Este bloque carga las etiquetas de clase desde classes.txt y las mapea a los índices en el DataFrame, creando una nueva columna 'class' con nombres legibles. Esto facilita la interpretación y análisis de los datos. El proceso es igual al del código anterior.

In [3]:
```
labels = open('classes.txt').read().splitlines()
classes = train_df['class index'].map(lambda i: labels[i-1])
train_df.insert(1, 'class', classes)
train_df
```

Out[3]:

	class index	class	title	description
0	3	Business	Wall St. Bears Claw Back Into the Black (Reuters)	Reuters - Short-sellers, Wall Street's dwindli...
1	3	Business	Carlyle Looks Toward Commercial Aerospace (Reu...	Reuters - Private investment firm Carlyle Grou...
2	3	Business	Oil and Economy Cloud Stocks' Outlook (Reuters)	Reuters - Soaring crude prices plus worries\ab...
3	3	Business	Iraq Halts Oil Exports from Main Southern Pipe...	Reuters - Authorities have halted oil export\f...
4	3	Business	Oil prices soar to all-time record, posing new...	AFP - Tearaway world oil prices, toppling reco...
...	...	...	...	...
119995	1	World	Pakistan's Musharraf Says Won't Quit as Army C...	KARACHI (Reuters) - Pakistani President Perve...
119996	2	Sports	Renteria signing a top-shelf deal	Red Sox general manager Theo Epstein acknowled...
119997	2	Sports	Saban not going to Dolphins yet	The Miami Dolphins will put their courtship of...
119998	2	Sports	Today's NFL games	PITTSBURGH at NY GIANTS Time: 1:30 p.m. Line: ...
119999	2	Sports	Nets get Carter from Raptors	INDIANAPOLIS -- All-Star Vince Carter was trad...

120000 rows × 4 columns

Let's inspect how balanced our examples are by using a bar plot.

Este bloque genera un gráfico de barras para mostrar la distribución de las clases en el conjunto de datos. Ayuda a verificar si las clases están equilibradas, lo cual es importante para el rendimiento del modelo. Similar al código anterior.

In [4]:
```
pd.value_counts(train_df['class']).plot.bar()
```

```
C:\Users\luism\AppData\Local\Temp\ipykernel_43288\1245903889.py:1: FutureWarning: pa
ndas.value_counts is deprecated and will be removed in a future version. Use pd.Seri
es(obj).value_counts() instead.
  pd.value_counts(train_df['class']).plot.bar()
```

Out[4]: <Axes: xlabel='class'>

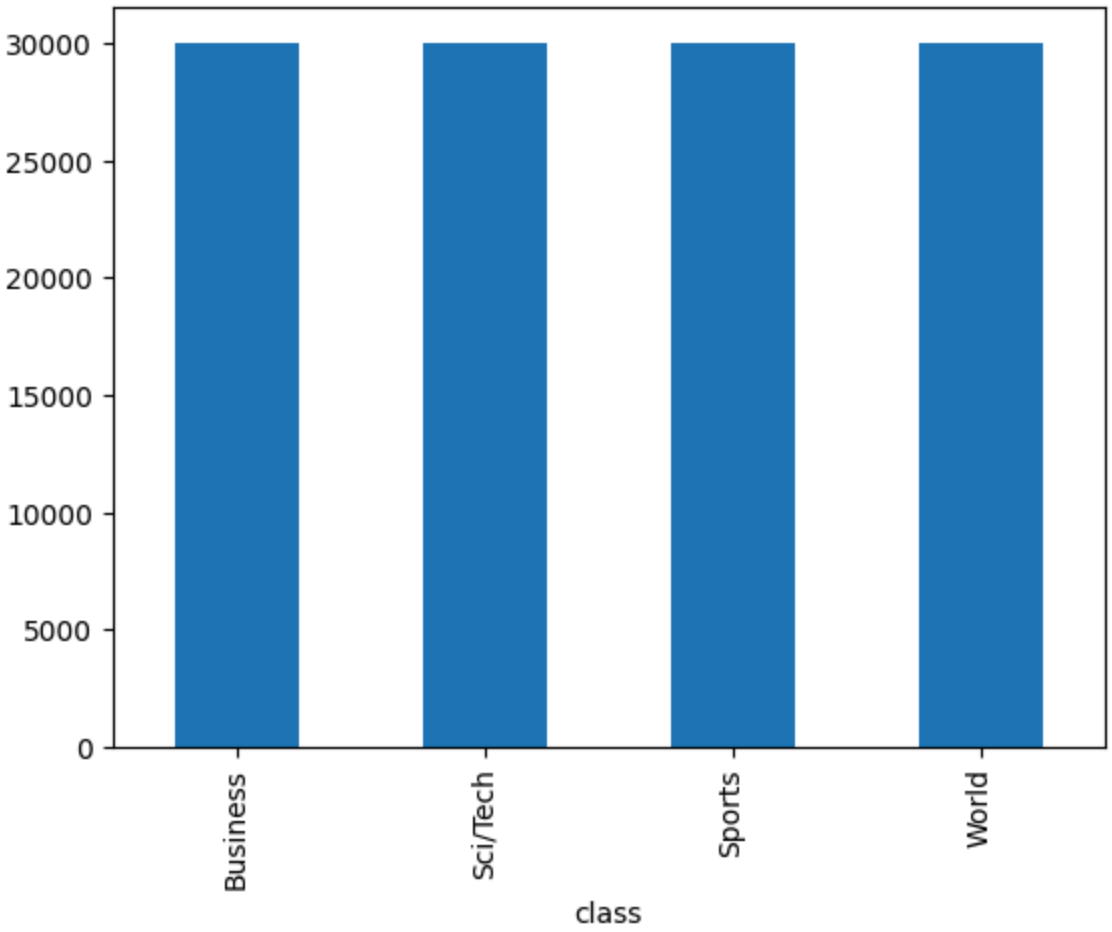

The classes are evenly distributed. That's great!

However, the text contains some spurious backslashes in some parts of the text. They are meant to represent newlines in the original text. An example can be seen below, between the words "dwindling" and "band".

Aquí se imprime la descripción del primer registro para inspeccionar el contenido y detectar posibles problemas de formato o caracteres no deseados. Esto ayuda a identificar necesidades de limpieza en el texto antes del preprocesamiento.

In [5]:
```
print(train_df.loc[0, 'description'])
```

```
Reuters - Short-sellers, Wall Street's dwindling\band of ultra-cynics, are seeing gr
een again.
```

We will replace the backslashes with spaces on the whole column using pandas replace method.

Este bloque limpia y prepara el texto combinando las columnas 'title' y 'description' en minúsculas, reemplazando las barras invertidas (\) por espacios. Esto asegura que el texto sea uniforme y esté libre de caracteres no deseados para el preprocesamiento posterior.

In [6]:
```
train_df['text'] = train_df['title'].str.lower() + " " + train_df['description'].st
train_df['text'] = train_df['text'].str.replace('\\', ' ', regex=False)
train_df
```

Out[6]:

	class index	class	title	description	text
0	3	Business	Wall St. Bears Claw Back Into the Black (Reuters)	Reuters - Short-sellers, Wall Street's dwindli...	wall st. bears claw back into the black (reute...
1	3	Business	Carlyle Looks Toward Commercial Aerospace (Reu...	Reuters - Private investment firm Carlyle Grou...	carlyle looks toward commercial aerospace (reu...
2	3	Business	Oil and Economy Cloud Stocks' Outlook (Reuters)	Reuters - Soaring crude prices plus worries\ab...	oil and economy cloud stocks' outlook (reuters...
3	3	Business	Iraq Halts Oil Exports from Main Southern Pipe...	Reuters - Authorities have halted oil export\f...	iraq halts oil exports from main southern pipe...
4	3	Business	Oil prices soar to all-time record, posing new...	AFP - Tearaway world oil prices, toppling reco...	oil prices soar to all-time record, posing new...
...	...	...	...	...	...
119995	1	World	Pakistan's Musharraf Says Won't Quit as Army C...	KARACHI (Reuters) - Pakistani President Perve...	pakistan's musharraf says won't quit as army c...
119996	2	Sports	Renteria signing a top-shelf deal	Red Sox general manager Theo Epstein acknowled...	renteria signing a top-shelf deal red sox gene...
119997	2	Sports	Saban not going to Dolphins yet	The Miami Dolphins will put their courtship of...	saban not going to dolphins yet the miami dolp...
119998	2	Sports	Today's NFL games	PITTSBURGH at NY GIANTS Time: 1:30 p.m. Line: ...	today's nfl games pittsburgh at ny giants time...
119999	2	Sports	Nets get Carter from Raptors	INDIANAPOLIS -- All-Star Vince Carter was trad...	nets get carter from raptors indianapolis -- a...

120000 rows × 5 columns

Now we will proceed to tokenize the title and description columns using NLTK's word_tokenize(). We will add a new column to our dataframe with the list of tokens.

Este bloque realiza la tokenización del texto para preparar los datos para el modelo. Utiliza word_tokenize para dividir el contenido de la columna 'text' en palabras individuales (tokens) y almacena el resultado en una nueva columna llamada 'tokens'. La tokenización es crucial porque convierte el texto en una forma más manejable, permitiendo que el modelo procese

palabras individuales en lugar de trabajar con oraciones completas. Además, el uso de progress_map permite visualizar el avance del proceso, lo cual es útil para conjuntos de datos grandes.

In [7]:
```
from nltk.tokenize import word_tokenize

train_df['tokens'] = train_df['text'].progress_map(word_tokenize)
train_df
```

```
  0%|          | 0/120000 [00:00<?, ?it/s]
```

Out[7]:

	class index	class	title	description	text	tokens
0	3	Business	Wall St. Bears Claw Back Into the Black (Reuters)	Reuters - Short-sellers, Wall Street's dwindli...	wall st. bears claw back into the black (reute...	[wall, st., bears, claw, back, into, the, blac...
1	3	Business	Carlyle Looks Toward Commercial Aerospace (Reu...	Reuters - Private investment firm Carlyle Grou...	carlyle looks toward commercial aerospace (reu...	[carlyle, looks, toward, commercial, aerospace...
2	3	Business	Oil and Economy Cloud Stocks' Outlook (Reuters)	Reuters - Soaring crude prices plus worries\ab...	oil and economy cloud stocks' outlook (reuters...	[oil, and, economy, cloud, stocks, ', outlook,...
3	3	Business	Iraq Halts Oil Exports from Main Southern Pipe...	Reuters - Authorities have halted oil export\f...	iraq halts oil exports from main southern pipe...	[iraq, halts, oil, exports, from, main, southe...
4	3	Business	Oil prices soar to all-time record, posing new...	AFP - Tearaway world oil prices, toppling reco...	oil prices soar to all-time record, posing new...	[oil, prices, soar, to, all-time, record, ,, p...
...	...	...	...	...	...	...
119995	1	World	Pakistan's Musharraf Says Won't Quit as Army C...	KARACHI (Reuters) - Pakistani President Perve...	pakistan's musharraf says won't quit as army c...	[pakistan, 's, musharraf, says, wo, n't, quit,...
119996	2	Sports	Renteria signing a top-shelf deal	Red Sox general manager Theo Epstein acknowled...	renteria signing a top-shelf deal red sox gene...	[renteria, signing, a, top-shelf, deal, red, s...
119997	2	Sports	Saban not going to Dolphins yet	The Miami Dolphins will put their courtship of...	saban not going to dolphins yet the miami dolp...	[saban, not, going, to, dolphins, yet, the, mi...
119998	2	Sports	Today's NFL games	PITTSBURGH at NY GIANTS Time: 1:30 p.m. Line: ...	today's nfl games pittsburgh at ny giants time...	[today, 's, nfl, games, pittsburgh, at, ny, gi...
119999	2	Sports	Nets get Carter from Raptors	INDIANAPOLIS -- All-Star Vince Carter was trad...	nets get carter from raptors	[nets, get, carter, from,

	class index	class	title	description	text	tokens
					indianapolis -- a...	raptors, indianapoli...

120000 rows × 6 columns

Now we will load the GloVe word embeddings.

Este bloque carga las embeddings preentrenadas de GloVe utilizando KeyedVectors de la biblioteca gensim. Las embeddings permiten convertir palabras en vectores numéricos que capturan relaciones semánticas. Aquí se cargan las embeddings desde un archivo, lo que permite al modelo aprovechar conocimiento previo sobre el lenguaje.

A diferencia del código anterior, que no usaba embeddings preentrenadas, este enfoque mejora el rendimiento del modelo al proporcionar representaciones más ricas y precisas de las palabras. Esto puede ayudar al modelo a generalizar mejor, especialmente con datos limitados.

In [8]:
```
from gensim.models import KeyedVectors
glove = KeyedVectors.load_word2vec_format("glove.6B.300d.txt", no_header=True)
glove.vectors.shape
```

Out[8]:
```
(400000, 300)
```

The word embeddings have been pretrained in a different corpus, so it would be a good idea to estimate how good our tokenization matches the GloVe vocabulary.

Este bloque analiza cuántas palabras en el conjunto de datos no están presentes en el vocabulario de GloVe. Se define una función para contar las palabras "desconocidas" y se calculan estadísticas como el total de tokens, el número y porcentaje de tokens desconocidos, y las palabras desconocidas más frecuentes. Esto permite evaluar la cobertura de las embeddings de GloVe en el dataset. A diferencia del código anterior, aquí se aprovechan embeddings preentrenadas para entender mejor el texto, mientras que antes se usaban vectores de características generados directamente de los tokens.

In [9]:
```
from collections import Counter

def count_unknown_words(data, vocabulary):
    counter = Counter()
    for row in tqdm(data):
        counter.update(tok for tok in row if tok not in vocabulary)
    return counter

# find out how many times each unknown token occurrs in the corpus
c = count_unknown_words(train_df['tokens'], glove.key_to_index)

# find the total number of tokens in the corpus
total_tokens = train_df['tokens'].map(len).sum()
```

```
# find some statistics about occurrences of unknown tokens
unk_tokens = sum(c.values())
percent_unk = unk_tokens / total_tokens
distinct_tokens = len(list(c))

print(f'total number of tokens: {total_tokens:,}')
print(f'number of unknown tokens: {unk_tokens:,}')
print(f'number of distinct unknown tokens: {distinct_tokens:,}')
print(f'percentage of unkown tokens: {percent_unk:.2%}')
print('top 50 unknown words:')
for token, n in c.most_common(10):
    print(f'\t{n}\t{token}')
```

```
  0%|          | 0/120000 [00:00<?, ?it/s]
total number of tokens: 5,273,733
number of unknown tokens: 65,844
number of distinct unknown tokens: 24,628
percentage of unkown tokens: 1.25%
top 50 unknown words:
        2984    /b
        2119    href=
        2117    /a
        1813    //www.investor.reuters.com/fullquote.aspx
        1813    target=/stocks/quickinfo/fullquote
        537     /p
        510     newsfactor
        471     cbs.mw
        431     color=
        417     /font
```

Glove embeddings seem to have a good coverage on this dataset -- only 1.25% of the tokens in the dataset are unknown, i.e., don't appear in the GloVe vocabulary.

Still, we will need a way to handle these unknown tokens. Our approach will be to add a new embedding to GloVe that will be used to represent them. This new embedding will be initialized as the average of all the GloVe embeddings.

We will also add another embedding, this one initialized to zeros, that will be used to pad the sequences of tokens so that they all have the same length. This will be useful when we train with mini-batches.

En este bloque se añaden nuevas embeddings a GloVe para manejar tokens desconocidos y el padding. Se definen los tokens [UNK] para palabras desconocidas y [PAD] para rellenar secuencias, cruciales para estandarizar la longitud de las entradas en el modelo. Las embeddings para [UNK] se inicializan como el promedio de todas las embeddings de GloVe, lo que representa una "palabra genérica", y las de [PAD] se inicializan en ceros para no influir en las predicciones. Luego, se agregan estas nuevas embeddings al vocabulario de GloVe y se obtienen sus identificadores (unk_id, pad_id).

In [10]:
```
# string values corresponding to the new embeddings
unk_tok = '[UNK]'
```

```
pad_tok = '[PAD]'

# initialize the new embedding values
unk_emb = glove.vectors.mean(axis=0)
pad_emb = np.zeros(300)

# add new embeddings to glove
glove.add_vectors([unk_tok, pad_tok], [unk_emb, pad_emb])

# get token ids corresponding to the new embeddings
unk_id = glove.key_to_index[unk_tok]
pad_id = glove.key_to_index[pad_tok]

unk_id, pad_id
```

Out[10]: (400000, 400001)

Este bloque divide el conjunto de datos de entrenamiento en dos partes: un conjunto de entrenamiento (train_df) y un conjunto de validación o desarrollo (dev_df), usando un 80% de los datos para entrenamiento. Esto permite evaluar el rendimiento del modelo durante el entrenamiento y ajustar hiperparámetros sin usar el conjunto de prueba final. Luego, se restablecen los índices de ambos DataFrames para facilitar el manejo de los datos.

A diferencia del código anterior, aquí se crea explícitamente un conjunto de validación, lo cual es una buena práctica para evitar el sobreajuste y ajustar mejor el modelo antes de la evaluación final.

In [11]:
```
from sklearn.model_selection import train_test_split

train_df, dev_df = train_test_split(train_df, train_size=0.8)
train_df.reset_index(inplace=True)
dev_df.reset_index(inplace=True)
```

We will now add a new column to our dataframe that will contain the padded sequences of token ids.

En este bloque se construye un vocabulario basado en el conjunto de entrenamiento. Se cuentan los tokens presentes usando value_counts y se filtran para incluir solo aquellos que aparecen más de 10 veces (threshold = 10). Esto ayuda a reducir el ruido eliminando palabras poco frecuentes que pueden no ser relevantes. Finalmente, se muestra el tamaño del vocabulario resultante.

Esta técnica es similar al enfoque del código anterior que también filtra tokens por frecuencia, pero aquí el vocabulario se usará junto con las embeddings de GloVe, proporcionando representaciones más ricas de las palabras que cumplan con el umbral.

In [12]:
```
threshold = 10
tokens = train_df['tokens'].explode().value_counts()
vocabulary = set(tokens[tokens > threshold].index.tolist())
print(f'vocabulary size: {len(vocabulary):,}')
```

```
vocabulary size: 17,446
```

Aquí se transforman los tokens en listas de identificadores (IDs) para usarlos como entradas del modelo. Primero, se determina la longitud máxima de los tokens en el conjunto de entrenamiento (max_tokens). Luego, se define la función get_id, que asigna un ID a cada token usando el vocabulario de GloVe y devuelve unk_id para palabras desconocidas o infrecuentes.

La función token_ids convierte listas de tokens en listas de IDs, añadiendo padding (pad_id) para que todas las secuencias tengan la misma longitud (max_tokens). Finalmente, se aplica esta función para crear una nueva columna 'token ids' en el DataFrame.

Esto es diferente del código anterior, que convertía los tokens en vectores de características sin embeddings preentrenadas. Aquí, se asegura que las secuencias sean consistentes en longitud, lo que es esencial para entrenar redes neuronales con mini-batches.

In [13]:
```
# find the length of the longest list of tokens
max_tokens = train_df['tokens'].map(len).max()

# return unk_id for infrequent tokens too
def get_id(tok):
    if tok in vocabulary:
        return glove.key_to_index.get(tok, unk_id)
    else:
        return unk_id

# function that gets a list of tokens and returns a list of token ids,
# with padding added accordingly
def token_ids(tokens):
    tok_ids = [get_id(tok) for tok in tokens]
    pad_len = max_tokens - len(tok_ids)
    return tok_ids + [pad_id] * pad_len

# add new column to the dataframe
train_df['token ids'] = train_df['tokens'].progress_map(token_ids)
train_df
```

```
  0%|          | 0/96000 [00:00<?, ?it/s]
```

Out[13]:

	index	class index	class	title	description	text	tokens	token ids
0	9116	1	World	Najaf's Residents Feel Trapped in Battle (AP)	AP - For nearly three weeks, Amer al-Jamali ha...	najaf's residents feel trapped in battle (ap) ...	[najaf, 's, residents, feel, trapped, in, batt...	[10709, 9, 1048, 998, 4799, 6, 903, 23, 1582, ...
1	99831	3	Business	U.S. FDA Adds Restrictions to Acne Drug	WASHINGTON (Reuters) - Roche's acne drug Accu...	u.s. fda adds restrictions to acne drug washi...	[u.s., fda, adds, restrictions, to, acne, drug...	[99, 5584, 2144, 3252, 4, 400000, 780, 289, 23...
2	10663	3	Business	Smithfield Foods Profit More Than Doubles	Smithfield Foods Inc. (SFD.N: Quote, Profile, ...	smithfield foods profit more than doubles smit...	[smithfield, foods, profit, more, than, double...	[34026, 5008, 1269, 56, 73, 4229, 34026, 5008,...
3	73175	4	Sci/Tech	PluggedIn: The OQO Is Not Just Another Handhel...	SAN FRANCISCO (Reuters) - A full-fledged Wind...	pluggedin: the oqo is not just another handhel...	[pluggedin, :, the, oqo, is, not, just, anothe...	[400000, 45, 0, 293697, 14, 36, 120, 170, 2099...
4	104494	4	Sci/Tech	IBM invigorates LTO tape storage	LTO (linear tape open)-based drives are invigo...	ibm invigorates lto tape storage lto (linear t...	[ibm, invigorates, lto, tape, storage, lto, (,...	[5199, 400000, 400000, 4143, 4418, 400000, 23,...
...	...	...	...	...	...	...	...	...
95995	89460	1	World	Bush, Blair See Hope for Palestinian State (AP)	AP - As Yasser Arafat was buried, President Bu...	bush, blair see hope for palestinian state (ap...	[bush, ,, blair, see, hope, for, palestinian, ...	[272, 1, 2356, 253, 824, 10, 463, 92, 23, 1582...
95996	60620	1	World	Ex-Soldiers Vow to Bring Order to	Ex-soldiers who helped topple former President...	ex-soldiers vow to bring order to	[ex-soldiers, vow, to, bring,	[223970, 12887, 4, 938, 460, 4,

	index	class index	class	title	description	text	tokens	token ids
				Haiti Capital		haiti capita...	order, to, haiti...	3836, 351, 223...
95997	34086	1	World	Musharraf says U.S. must address root of terro...	Reuters - The United States could lose its war...	musharraf says u.s. must address root of terro...	[musharraf, says, u.s., must, address, root, o...	[3820, 210, 99, 390, 1476, 5440, 3, 1291, 23, ...
95998	58067	1	World	Nuclear materials #39;vanish #39; in Iraq	Equipment and materials that could be used to ...	nuclear materials #39;vanish #39; in iraq equ...	[nuclear, materials, #, 39, ;, vanish, #, 39, ...	[490, 2176, 2749, 3403, 89, 25736, 2749, 3403,...
95999	92975	4	Sci/Tech	In Brief: Bowstreet unveils pre-packaged porta...	Bowstreet this week launched its Enterprise Po...	in brief: bowstreet unveils pre-packaged porta...	[in, brief, :, bowstreet, unveils, pre-package...	[6, 2461, 45, 400000, 20465, 400000, 12174, 83...

96000 rows × 8 columns

Este bloque convierte los tokens del conjunto de validación en listas de IDs con padding, asegurando que todas las secuencias tengan la misma longitud (max_tokens). Esto permite usar los datos de validación de forma consistente con el conjunto de entrenamiento para evaluar el modelo. A diferencia del código anterior, aquí se prepara explícitamente un conjunto de validación para ajustar el rendimiento sin depender del conjunto de prueba final.

In [14]:
```
max_tokens = dev_df['tokens'].map(len).max()
dev_df['token ids'] = dev_df['tokens'].progress_map(token_ids)
dev_df
```

```
  0%|          | 0/24000 [00:00<?, ?it/s]
```

Out[14]:

	index	class index	class	title	description	text	tokens	tok i
0	60974	1	World	Sharon Accepts Plan to Reduce Gaza Army Operat...	Israeli Prime Minister Ariel Sharon accepted a...	sharon accepts plan to reduce gaza army operat...	[sharon, accepts, plan, to, reduce, gaza, army...	[254 988 394, 168 116 33 957,
1	50391	4	Sci/Tech	Internet Key Battleground in Wildlife Crime Fight	Why trawl through a sweaty illegal\wildlife ma...	internet key battleground in wildlife crime fi...	[internet, key, battleground, in, wildlife, cr...	[92 63 1494 444 134 83 73 400
2	9307	3	Business	July Durable Good Orders Rise 1.7 Percent	America's factories saw orders for costly manu...	july durable good orders rise 1.7 percent amer...	[july, durable, good, orders, rise, 1.7, perce...	[37 1069 21 194 102 626 7 45 9
3	35221	3	Business	Growing Signs of a Slowing on Wall Street	all Street #39;s earnings growth, fueled by tw...	growing signs of a slowing on wall street all ...	[growing, signs, of, a, slowing, on, wall, str...	[98 186 3, 651 1 101 49 6 491
4	40081	1	World	The New Faces of Reality TV	The introduction of children to the genre was ...	the new faces of reality tv the introduction o...	[the, new, faces, of, reality, tv, the, introd...	[0, 5 191 253 816, 434 3, 27 4
...	...	...	...	...	...	...	...	
23995	49572	1	World	Iraqi Kidnappers Release 2	Two Indonesian women held	iraqi kidnappers release 2	[iraqi, kidnappers, release, 2,	[71 934 71 23

	index	class index	class	title	description	text	tokens	tok i
				Indonesian Women	hostage for several ...	indonesian women tw...	indonesian, wo...	265 26 5 265 266
23996	40409	4	Sci/Tech	Big Wi-Fi Project for Philadelphia	What would Benjamin Franklin say? Philadelphia...	big wi-fi project for philadelphia what would ...	[big, wi-fi, project, for, philadelphia, what,...	[36 3930 71 1 220 10 5 406 503
23997	70470	2	Sports	Owen scores again	Michael Owen scored the winner for Real Madrid...	owen scores again michael owen scored the winn...	[owen, scores, again, michael, owen, scored, t...	[711 277 37 78 711 878, 136 10
23998	7941	4	Sci/Tech	US Online Retail Sales Expected To Double In S...	Online retail sales in the US are expected to ...	us online retail sales expected to double in s...	[us, online, retail, sales, expected, to, doub...	[9 129 264 52 287, 127 6, 22 82
23999	42303	1	World	Egyptian holding company says it has heard fou...	Egypt said Tuesday that Iraqi kidnappers had f...	egyptian holding company says it has heard fou...	[egyptian, holding, company, says, it, has, he...	[243 138 12 21 20, 3 143 13 2434

24000 rows × 8 columns

Now we will get a numpy 2-dimensional array corresponding to the token ids, and a 1-dimensional array with the gold classes. Note that the classes are one-based (i.e., they start at one), but we need them to be zero-based, so we need to subtract one from this array.

Se define una clase personalizada MyDataset, que extiende Dataset de PyTorch para manejar el conjunto de datos de manera estructurada. La clase permite crear objetos que almacenan las entradas (x) y sus etiquetas correspondientes (y). Implementa métodos para obtener la longitud del dataset (**len**) y para acceder a elementos específicos (**getitem**), devolviendo tensores de PyTorch que pueden ser usados directamente en el modelo.

Esto es útil para cargar los datos en mini-batches durante el entrenamiento y la evaluación, asegurando que el modelo procese los datos de manera eficiente. A diferencia del código anterior, esta estructura facilita el manejo de datos cuando se trabaja con redes neuronales más complejas.

In [15]:
```
from torch.utils.data import Dataset

class MyDataset(Dataset):
    def __init__(self, x, y):
        self.x = x
        self.y = y

    def __len__(self):
        return len(self.y)

    def __getitem__(self, index):
        x = torch.tensor(self.x[index])
        y = torch.tensor(self.y[index])
        return x, y
```

Next, we construct our PyTorch model, which is a feed-forward neural network with two layers:

Este bloque define una clase Model, que representa una red neuronal para la clasificación de texto utilizando embeddings de palabras preentrenadas. La red tiene una capa de embeddings que convierte las secuencias de IDs en vectores, seguida de capas feed-forward para procesar y clasificar las entradas.

- Inicialización: La red toma las embeddings preentrenadas (vectors) y las convierte a tensores de PyTorch, usando pad_id para ignorar el padding durante el cálculo. Se define una capa de embeddings con las vectores de GloVe y luego se añaden capas lineales con activación ReLU y dropout, que ayudan a evitar el sobreajuste.
- Método forward: Calcula la salida de la red. Primero, ignora el padding, obtiene las embeddings para cada token, y calcula la media de las embeddings para representar la secuencia. Luego, pasa estos valores por las capas feed-forward para obtener la clasificación final.

In [16]:
```
from torch import nn
import torch.nn.functional as F

class Model(nn.Module):
```

```
    def __init__(self, vectors, pad_id, hidden_dim, output_dim, dropout):
        super().__init__()
        # embeddings must be a tensor
        if not torch.is_tensor(vectors):
            vectors = torch.tensor(vectors)
        # keep padding id
        self.padding_idx = pad_id
        # embedding layer
        self.embs = nn.Embedding.from_pretrained(vectors, padding_idx=pad_id)
        # feedforward layers
        self.layers = nn.Sequential(
            nn.Dropout(dropout),
            nn.Linear(vectors.shape[1], hidden_dim),
            nn.ReLU(),
            nn.Dropout(dropout),
            nn.Linear(hidden_dim, output_dim),
        )

    def forward(self, x):
        # get boolean array with padding elements set to false
        not_padding = torch.isin(x, self.padding_idx, invert=True)
        # get lengths of examples (excluding padding)
        lengths = torch.count_nonzero(not_padding, axis=1)
        # get embeddings
        x = self.embs(x)
        # calculate means
        x = x.sum(dim=1) / lengths.unsqueeze(dim=1)
        # pass to rest of the model
        output = self.layers(x)
        # calculate softmax if we're not in training mode
        #if not self.training:
        #    output = F.softmax(output, dim=1)
        return output
```

Next, we implement the training procedure. We compute the loss and accuracy on the development partition after each epoch.

Este bloque configura y entrena la red neuronal para la clasificación de texto. Primero, se definen los hiperparámetros clave (tasa de aprendizaje, tamaño del batch, dimensiones de la red) y se inicializa el modelo con embeddings de GloVe, una función de pérdida (CrossEntropyLoss) y el optimizador Adam. Los datos se organizan en DataLoaders para facilitar el entrenamiento en mini-batches.

Durante el entrenamiento, el modelo procesa batches de datos, calcula predicciones, retropropaga el error y ajusta los parámetros. Al final de cada época, se evalúa en el conjunto de validación, calculando la pérdida y precisión para monitorear el rendimiento y ajustar el modelo.

A diferencia del enfoque anterior, este usa embeddings preentrenadas y un modelo de red más complejo con optimizaciones adicionales (Adam y dropout) para mejorar el rendimiento y la generalización.

In [17]:
```
from torch import optim
from torch.utils.data import DataLoader
from sklearn.metrics import accuracy_score

# hyperparameters
lr = 1e-3
weight_decay = 0
batch_size = 500
shuffle = True
n_epochs = 5
hidden_dim = 50
output_dim = len(labels)
dropout = 0.1
vectors = glove.vectors

# initialize the model, loss function, optimizer, and data-loader
model = Model(vectors, pad_id, hidden_dim, output_dim, dropout).to(device)
loss_func = nn.CrossEntropyLoss()
optimizer = optim.Adam(model.parameters(), lr=lr, weight_decay=weight_decay)
train_ds = MyDataset(train_df['token ids'], train_df['class index'] - 1)
train_dl = DataLoader(train_ds, batch_size=batch_size, shuffle=shuffle)
dev_ds = MyDataset(dev_df['token ids'], dev_df['class index'] - 1)
dev_dl = DataLoader(dev_ds, batch_size=batch_size, shuffle=shuffle)

train_loss = []
train_acc = []

dev_loss = []
dev_acc = []

# train the model
for epoch in range(n_epochs):
    losses = []
    gold = []
    pred = []
    model.train()
    for X, y_true in tqdm(train_dl, desc=f'epoch {epoch+1} (train)'):
        # clear gradients
        model.zero_grad()
        # send batch to right device
        X = X.to(device)
        y_true = y_true.to(device)
        # predict label scores
        y_pred = model(X)
        # compute loss
        loss = loss_func(y_pred, y_true)
        # accumulate for plotting
        losses.append(loss.detach().cpu().item())
        gold.append(y_true.detach().cpu().numpy())
        pred.append(np.argmax(y_pred.detach().cpu().numpy(), axis=1))
        # backpropagate
        loss.backward()
        # optimize model parameters
        optimizer.step()
    train_loss.append(np.mean(losses))
```

```
    train_acc.append(accuracy_score(np.concatenate(gold), np.concatenate(pred)))

    model.eval()
    with torch.no_grad():
        losses = []
        gold = []
        pred = []
        for X, y_true in tqdm(dev_dl, desc=f'epoch {epoch+1} (dev)'):
            X = X.to(device)
            y_true = y_true.to(device)
            y_pred = model(X)
            loss = loss_func(y_pred, y_true)
            losses.append(loss.cpu().item())
            gold.append(y_true.cpu().numpy())
            pred.append(np.argmax(y_pred.cpu().numpy(), axis=1))
        dev_loss.append(np.mean(losses))
        dev_acc.append(accuracy_score(np.concatenate(gold), np.concatenate(pred)))
```

```
epoch 1 (train):   0%|          | 0/192 [00:00<?, ?it/s]
epoch 1 (dev):   0%|          | 0/48 [00:00<?, ?it/s]
epoch 2 (train):   0%|          | 0/192 [00:00<?, ?it/s]
epoch 2 (dev):   0%|          | 0/48 [00:00<?, ?it/s]
epoch 3 (train):   0%|          | 0/192 [00:00<?, ?it/s]
epoch 3 (dev):   0%|          | 0/48 [00:00<?, ?it/s]
epoch 4 (train):   0%|          | 0/192 [00:00<?, ?it/s]
epoch 4 (dev):   0%|          | 0/48 [00:00<?, ?it/s]
epoch 5 (train):   0%|          | 0/192 [00:00<?, ?it/s]
epoch 5 (dev):   0%|          | 0/48 [00:00<?, ?it/s]
```

Let's plot the loss and accuracy on dev:

Aquí se genera un gráfico que muestra cómo cambia la pérdida (loss) en cada época para los conjuntos de entrenamiento y validación. Ayuda a visualizar el aprendizaje del modelo y detectar problemas como el sobreajuste, comparando las pérdidas de ambos conjuntos durante el entrenamiento.

In [18]:
```
import matplotlib.pyplot as plt
%matplotlib inline

x = np.arange(n_epochs) + 1

plt.plot(x, train_loss)
plt.plot(x, dev_loss)
plt.legend(['train', 'dev'])
plt.xlabel('epoch')
plt.ylabel('loss')
plt.grid(True)
```

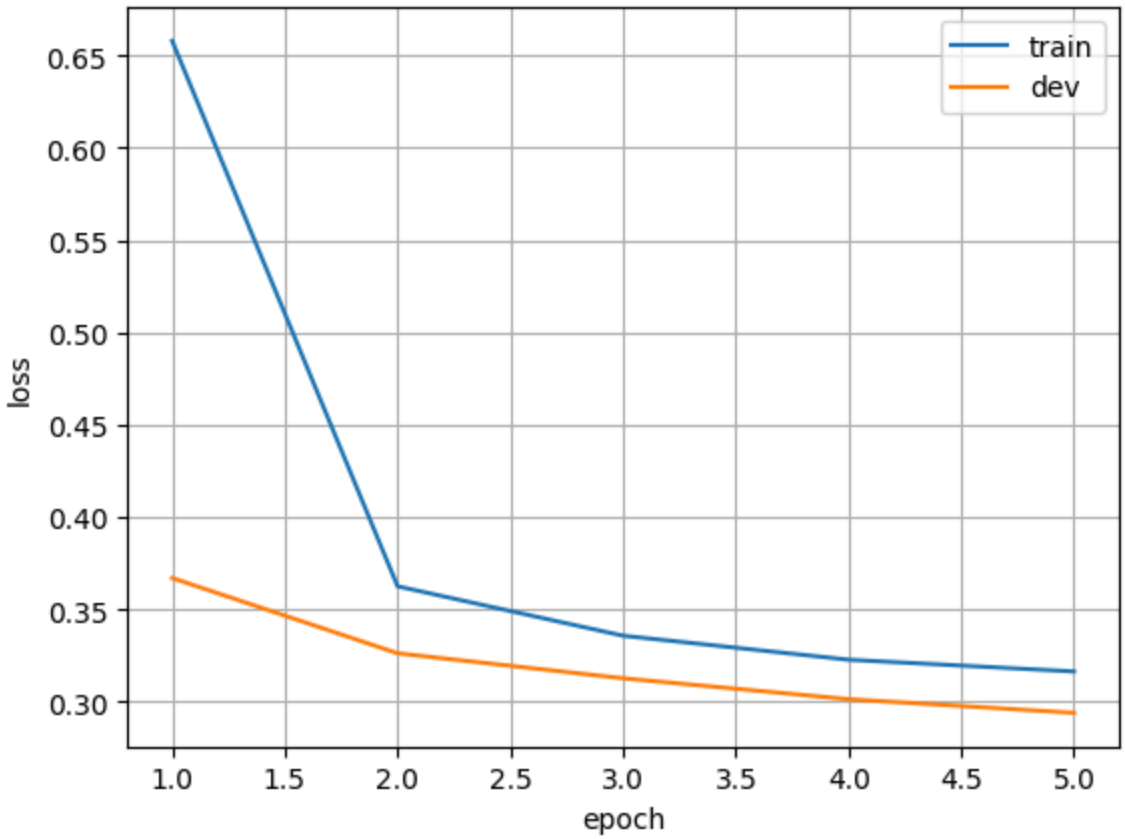

Este bloque grafica la precisión del modelo en cada época para los conjuntos de entrenamiento y validación, permitiendo evaluar mejoras en el rendimiento y detectar posibles problemas de sobreajust

In [19]:
```
plt.plot(x, train_acc)
plt.plot(x, dev_acc)
plt.legend(['train', 'dev'])
plt.xlabel('epoch')
plt.ylabel('accuracy')
plt.grid(True)
```

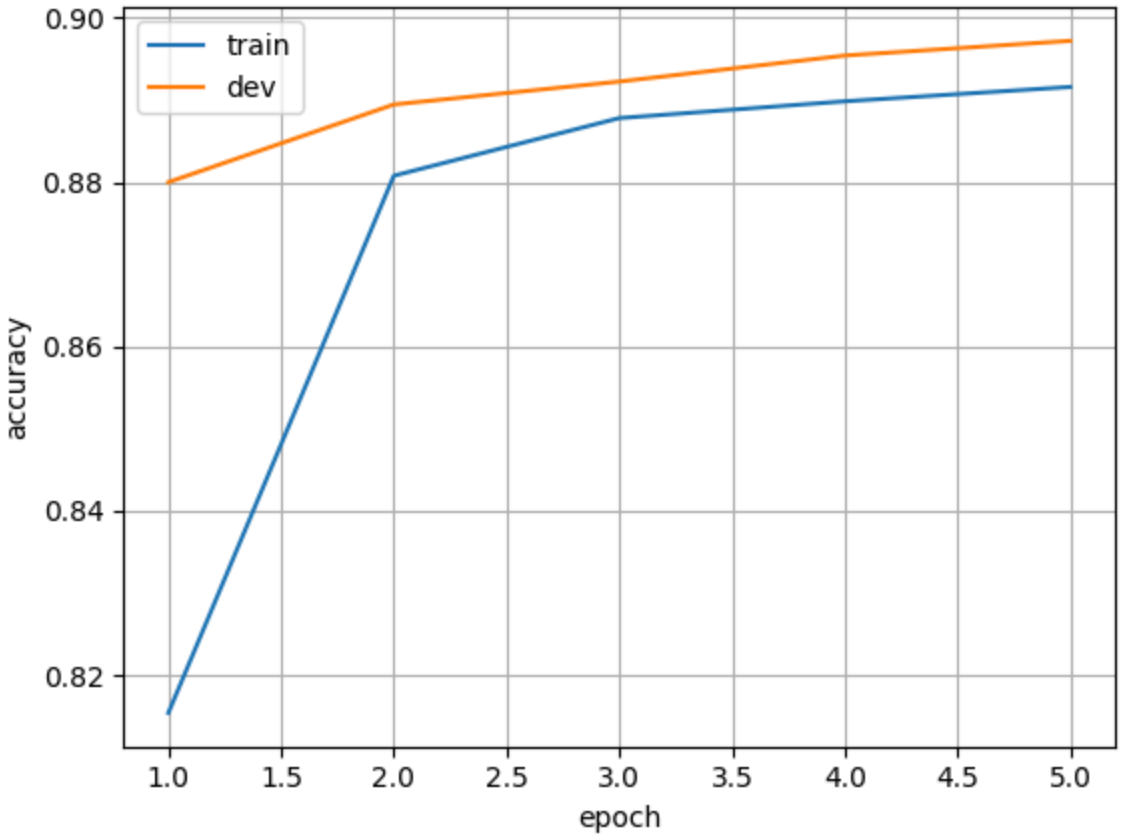

Next, we evaluate on the testing partition:

Este bloque aplica el mismo preprocesamiento que se hizo en los datos de entrenamiento y validación, pero ahora al conjunto de prueba. Se carga el dataset, se limpian y combinan los textos, se tokenizan y luego se convierten los tokens en listas de IDs, añadiendo padding para que todas las secuencias tengan la misma longitud. A diferencia del código anterior, aquí se utilizan embeddings preentrenadas de GloVe y tokens especiales [UNK] y [PAD], lo que permite manejar mejor palabras desconocidas y garantizar consistencia en las secuencias, facilitando una evaluación precisa del modelo.

In [21]:
```
# repeat all preprocessing done above, this time on the test set
test_df = pd.read_csv('test.csv', header=None)
test_df.columns = ['class index', 'title', 'description']
test_df['text'] = test_df['title'].str.lower() + " " + test_df['description'].str.l
test_df['text'] = test_df['text'].str.replace('\\', ' ', regex=False)
test_df['tokens'] = test_df['text'].progress_map(word_tokenize)
max_tokens = dev_df['tokens'].map(len).max()
test_df['token ids'] = test_df['tokens'].progress_map(token_ids)
```

```
  0%|          | 0/7600 [00:00<?, ?it/s]
  0%|          | 0/7600 [00:00<?, ?it/s]
```

Por último, se evalúa el modelo en el conjunto de prueba. Primero, se cambia el modelo a modo de evaluación (model.eval()), desactivando funciones específicas del entrenamiento, como dropout. Luego, se crea un DataLoader para manejar los datos de prueba en mini-

batches, y se desactivan los cálculos de gradientes para ahorrar memoria y acelerar el proceso.

Durante la evaluación, el modelo predice las clases para cada batch de datos y almacena los resultados. Al final, se usa classification_report de sklearn para generar un informe que muestra métricas como precisión, recall y F1-score para cada clase, proporcionando una evaluación detallada del rendimiento final.

A diferencia del código anterior, este enfoque maneja los datos de prueba con embeddings preentrenadas y padding consistente, lo que permite que el modelo aproveche mejor las representaciones de palabras y evalúe las secuencias de forma más robusta.

In [22]:
```
from sklearn.metrics import classification_report

# set model to evaluation mode
model.eval()

dataset = MyDataset(test_df['token ids'], test_df['class index'] - 1)
data_loader = DataLoader(dataset, batch_size=batch_size)
y_pred = []

# don't store gradients
with torch.no_grad():
    for X, _ in tqdm(data_loader):
        X = X.to(device)
        # predict one class per example
        y = torch.argmax(model(X), dim=1)
        # convert tensor to numpy array (sending it back to the cpu if needed)
        y_pred.append(y.cpu().numpy())
        # print results
    print(classification_report(dataset.y, np.concatenate(y_pred), target_names=lab
```

```
  0%|          | 0/16 [00:00<?, ?it/s]
              precision    recall  f1-score   support

       World       0.92      0.88      0.90      1900
      Sports       0.95      0.97      0.96      1900
    Business       0.85      0.86      0.85      1900
    Sci/Tech       0.86      0.87      0.87      1900

    accuracy                           0.90      7600
   macro avg       0.90      0.90      0.90      7600
weighted avg       0.90      0.90      0.90      7600
```